CC3045: Deep Learning

Laboratorio 10

Entrega final: Tasks 1 a 4

Milton Polanco - 23471

Configuración	Valor
Semilla aleatoria	42
Modelo de visión	ResNet-18 preentrenado en ImageNet
Modelo tabular	Gradient Boosting, 200 árboles, profundidad 3
Partición	80 % entrenamiento, 20 % prueba, estratificada
Fondo principal SHAP	100 instancias de entrenamiento

El análisis se apoya en las cifras y figuras producidas por la ejecución incluida en el notebook. Las probabilidades se reportan para la clase indicada; en crédito, *good* se codifica como 1 y *bad* como 0.

Declaración de herramientas de apoyo. Se utilizó asistencia de IA para apoyar la escritura de fórmulas.

Task 1: Grad-CAM y CAM

Task 1.1: Modelo, preprocesamiento e imágenes

Se cargó ResNet-18 con pesos de ImageNet y se fijó en modo de evaluación. Cada imagen se redimensionó a 256 píxeles en el lado corto, se recortó al centro a 224×224 y se normalizó por canal con media $(0.485, 0.456, 0.406)$ y desviación estándar $(0.229, 0.224, 0.225)$.



Figura 1: *Imágenes después del preprocesamiento geométrico. En (c), el recuadro del perro es* $(58, 20, 174, 214)$ *en coordenadas* $(x_{\text{mín}}, y_{\text{mín}}, x_{\text{máx}}, y_{\text{máx}})$.

Cuadro 1: *Cinco clases de mayor probabilidad para cada imagen.*

Imagen	Rango	Clase	Probabilidad
(a)	1	Samoyed	0.884793
(a)	2	Arctic fox	0.045711
(a)	3	white wolf	0.044211
(a)	4	Pomeranian	0.005623
(a)	5	Great Pyrenees	0.004655
(b)	1	Rhodesian ridgeback	0.649178
(b)	2	American Staffordshire terrier	0.106260
(b)	3	bull mastiff	0.053913
(b)	4	Great Dane	0.051081
(b)	5	boxer	0.050373
(c)	1	Shetland sheepdog	0.967136
(c)	2	collie	0.027508
(c)	3	Pomeranian	0.003798
(c)	4	shopping basket	0.000333
(c)	5	Pembroke	0.000296

La imagen (a) se reconoce como *Samoyed* con probabilidad 0.884793. En (b), las cinco primeras clases son razas de perro y el gato no aparece entre ellas; la evidencia del perro domina la predicción global. En (c), el perro se reconoce como *Shetland sheepdog* con 0.967136. *Shopping basket* aparece en cuarto lugar, con 0.000333.

Fuentes de las imágenes. (a) PyTorch Hub: *dog.jpg*. (b) Peretz Partensky, Wikimedia Commons: *Cat and dog standoff*, CC BY-SA 2.0. (c) Kokostephi, Wikimedia Commons: *Shetland Sheepdog in Shopping Cart at Petco*, CC0.

Task 1.2: Grad-CAM desde cero

Se registró un hook de avance sobre `layer4` para guardar las activaciones A de 512 canales y tamaño 7×7, y un hook de retroceso para guardar el gradiente del logit de la clase antes del softmax. Para cada canal se calculó

$$\alpha_k^c = \frac{1}{49} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}, \qquad L^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k \right).$$

El mapa se amplió a 224×224 con interpolación bilineal y se normalizó con su mínimo y máximo.

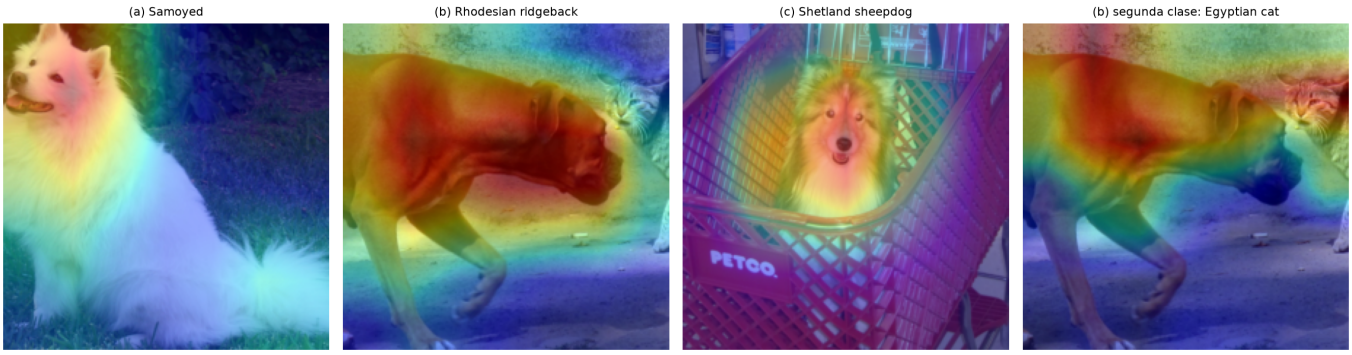


Figura 2: *Grad-CAM para la clase principal de cada imagen y, en (b), para la mejor clase felina: Egyptian cat.*

En (a) el mapa cubre el cuerpo y la cabeza del perro. En (b), los mapas de *Rhodesian ridgeback* y *Egyptian cat* cambian su énfasis espacial, aunque conservan una región compartida cerca del contacto entre los animales. En (c), la activación principal cae sobre el perro y parte del carrito inmediato.

Task 1.3: Verificación de CAM y su relación con Grad-CAM

Como ResNet-18 aplica promedio global antes de la capa lineal, CAM se obtiene sin gradientes mediante

$$M_{ij}^c = \sum_k w_k^c A_{ij}^k.$$

La descomposición esperada es $\frac{1}{49} \sum_{i,j} M_{ij}^c + b^c = y^c$. Además, antes de ReLU y normalización debe cumplirse $49 L^c = M^c$.

Cuadro 2: *Comprobaciones numéricas entre CAM y Grad-CAM.*

Imagen	Clase	Logit	CAM+b	Error logit	Error $49L$	Error norm.
(a)	Samoyed	16.273741	16.273743	1.907×10^{-6}	7.629×10^{-6}	1.788×10^{-7}
(b)	Rhodesian ridgeback	14.713373	14.713374	9.537×10^{-7}	3.815×10^{-6}	1.788×10^{-7}
(c)	Shetland sheepdog	17.980591	17.980591	0	7.629×10^{-6}	1.192×10^{-7}

La descomposición del logit coincide hasta un máximo de 1.91×10^{-6}. El error máximo entre 49 veces Grad-CAM sin ReLU y CAM es 7.63×10^{-6}; después de ReLU y normalización, el máximo es 1.79×10^{-7}. Las diferencias corresponden al redondeo de precisión simple.

Task 1.4: Análisis cuantitativo

(a) Gradientes y pesos. La derivada es constante en las 49 posiciones porque el pooling global promedia cada canal antes de la capa lineal:

$$\frac{\partial y^c}{\partial A_{ij}^k} = \frac{w_k^c}{49}.$$

Cuadro 3: *Comparación de α_k^c contra $w_k^c/49$ en los cinco canales de mayor $|w|$.*

Canal	α observado	$w/49$	Error relativo
31	0.0070189578	0.0070189578	0
83	0.0052330079	0.0052330079	0
314	0.0051479875	0.0051479880	9.046×10^{-8}
454	0.0045764870	0.0045764870	0
378	0.0044133649	0.0044133654	1.055×10^{-7}

Tres canales coinciden exactamente en la representación utilizada. Los otros dos tienen errores relativos cercanos a 10^{-7}. El orden de las sumas, los promedios y la retropropagación en `float32` explica que el resultado no sea cero exacto.



Figura 3: *Comparación espacial de las dos clases de (b) y mapa de (c) con el recuadro del objeto.*

(b) Separación de clases. La IoU entre los píxeles del 20 % superior es 0.224668. Este valor indica que el mapa discrimina buena parte de la evidencia del perro y del gato, aunque existe solapamiento. La resolución original de 7×7 impone un paso efectivo de 32 píxeles: dos objetos pequeños o cercanos pueden compartir una celda y no admiten una frontera precisa.

(c) Fondo y prueba causal. El 69.55 % de la masa normalizada cae dentro del recuadro. Al neutralizar el exterior, P(Shetland sheepdog) baja de 0.967136 a 0.819089, un cambio de -0.148047. El objeto concentra la mayoría de la evidencia, pero el exterior aporta soporte medible. Hay dependencia contextual, aunque no un atajo dominante, porque la clase conserva probabilidad 0.819089 sin el fondo original.

Task 2: Explicaciones de riesgo de crédito

Task 2.1: Datos y modelo base

German Credit contiene 1,000 solicitudes, 7 variables numéricas y 13 categóricas. Se codificó *good* como 1 y *bad* como 0. El codificador ordinal se ajustó solo con entrenamiento. Los códigos son arbitrarios y el árbol puede tratarlos como si existiera un orden y una distancia; esta es una limitación para interpretar divisiones y atribuciones.

Cuadro 4: *Desempeño sobre el conjunto de prueba.*

Métrica	Resultado
Exactitud	0.775
AUC	0.765

El AUC de 0.765 indica una separación útil pero imperfecta. Las explicaciones deben acompañarse de métricas de fidelidad y no presentarse como justificaciones causales.

Task 2.2: TreeSHAP intervencional

La salida explicada es el log-odds de `decision_function`. El fondo contiene 100 instancias de entrenamiento seleccionadas sin reemplazo con semilla 42.

Cuadro 5: *Comprobaciones principales de TreeSHAP.*

Comprobación	Resultado
Error absoluto máximo de eficiencia	9.722×10^{-8}
Valor base SHAP, log-odds	1.430742147
Media del log-odds sobre el fondo	1.430742147
Spearman entre rankings completos	0.649624

La eficiencia se cumple hasta 9.72×10^{-8} y el valor base coincide con la media del fondo en todos los dígitos mostrados. Esto valida la escala y la referencia utilizadas.

Cuadro 6: *Cinco variables principales según SHAP y permutación.*

Rango	SHAP	mean $\lvert\phi\rvert$	Permutación	Caída AUC
1	checking_status	0.760287	checking_status	0.119000
2	purpose	0.511731	credit_amount	0.076250
3	credit_amount	0.490213	duration	0.057905
4	duration	0.391748	credit_history	0.039643
5	savings_status	0.296328	savings_status	0.026155

Ambos métodos colocan `checking_status` primero. SHAP eleva `purpose` al segundo lugar, mientras permutación prioriza `credit_amount` y `duration`. La correlación de 0.649624 muestra acuerdo moderado: ambos métodos responden preguntas diferentes.

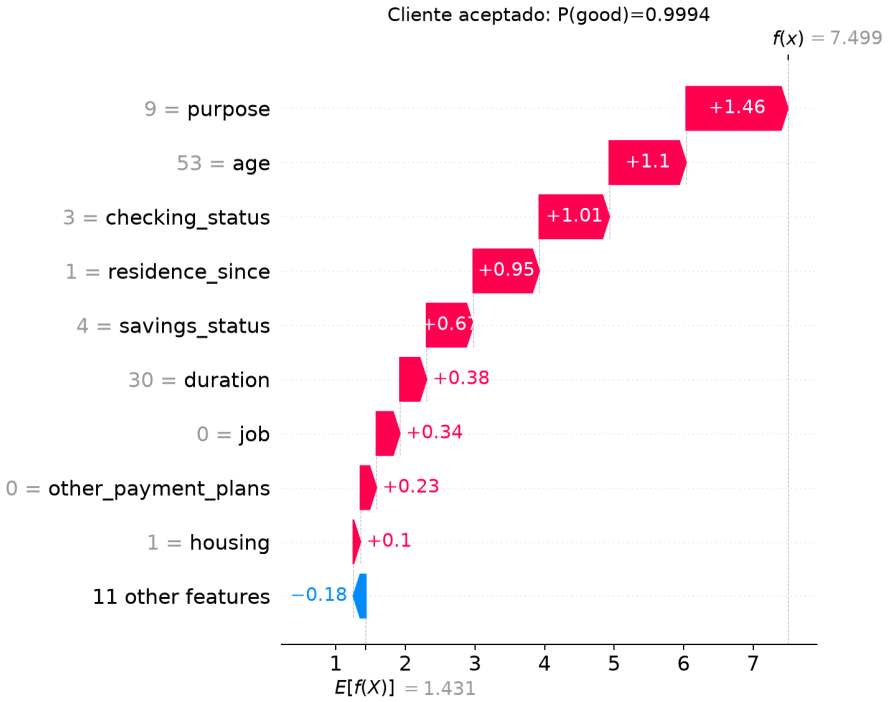


Figura 4: *Cliente aceptado, posición 50 del conjunto de prueba,* $P(good) = 0.999447$.

Las contribuciones de mayor magnitud son positivas: *purpose* (+1.463294), *age* (+1.104481) y *checking status* (+1.006869). Las tres desplazan el log-odds hacia *good*.

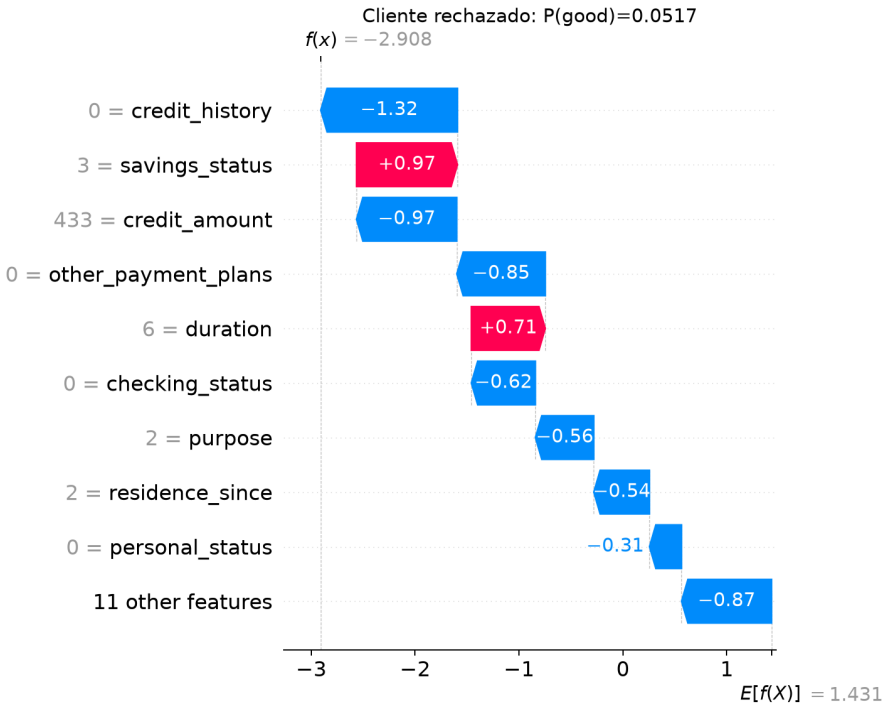


Figura 5: *Cliente rechazado, posición 76 del conjunto de prueba,* $P(good) = 0.051742$.

En el cliente rechazado, `credit_history` (−1.316188) y `credit_amount` (−0.965395) empujan hacia *bad*; `savings_status` (+0.972107) compensa parte del efecto. El signo describe el cambio en log-odds respecto al fondo, no una relación causal.

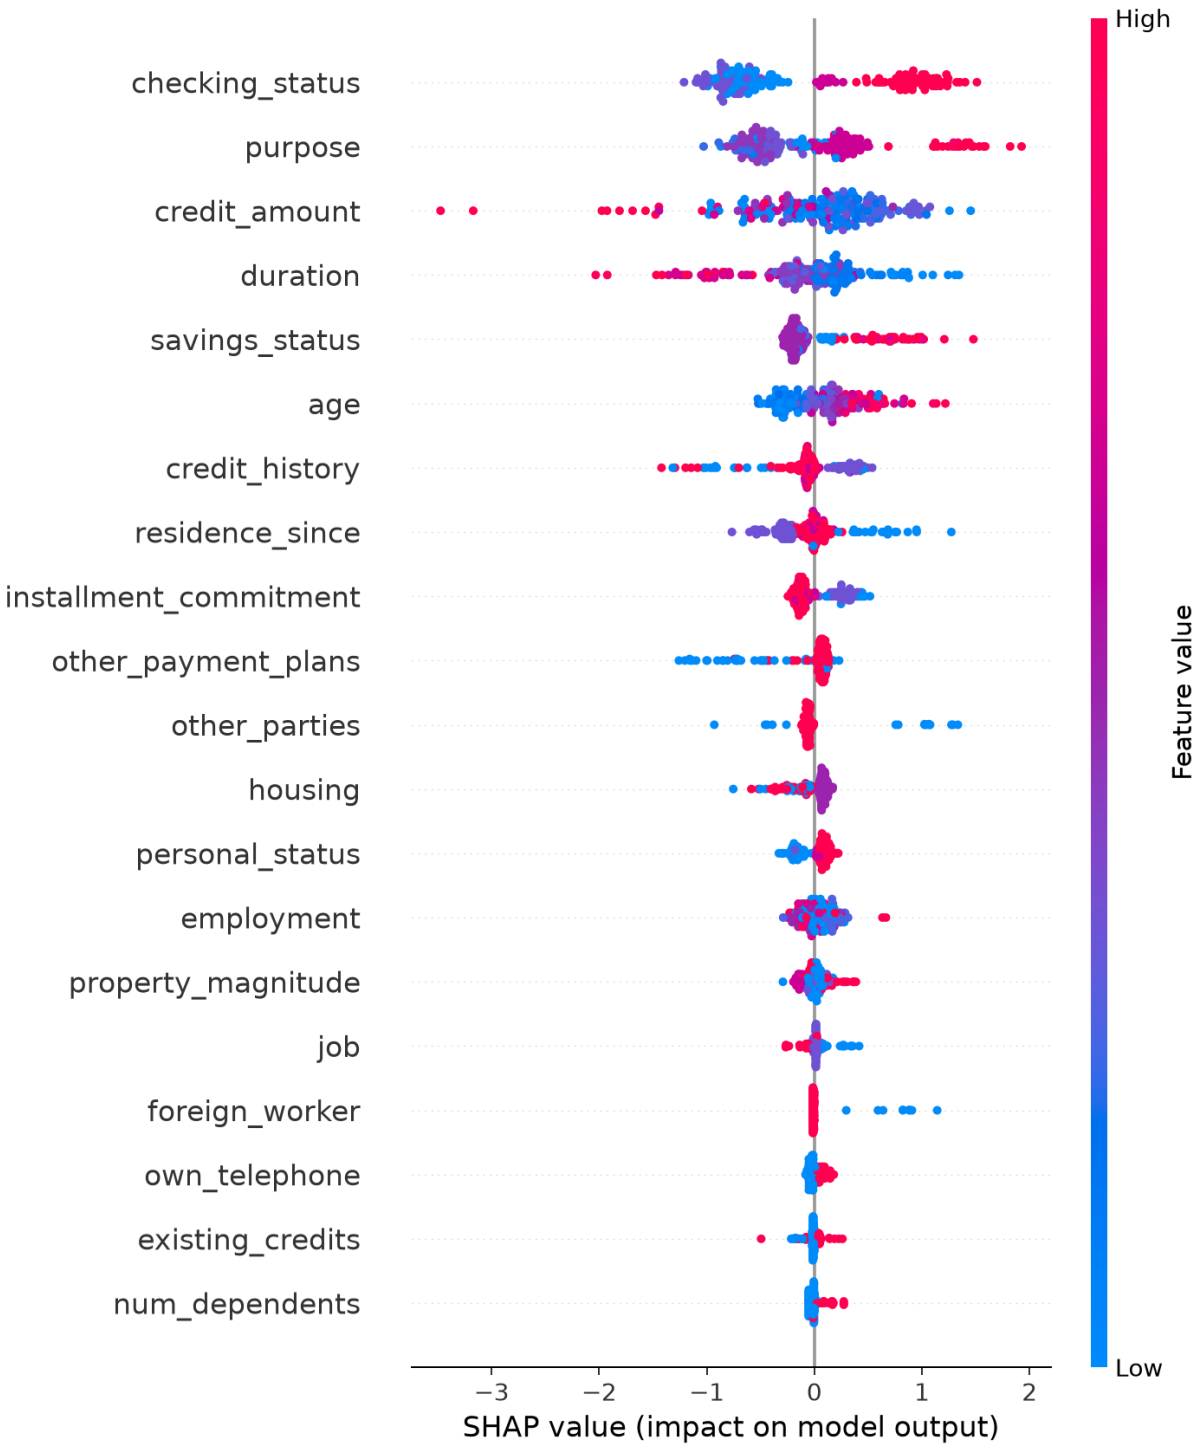


Figura 6: *Beeswarm global del conjunto de prueba. La posición horizontal es la contribución al log-odds y el color representa el valor codificado.*

Task 2.3: Variable redundante

La variable numérica de mayor importancia fue `credit_amount`, con mean $|\phi| = 0.490213$. Se creó una copia con ruido gaussiano de escala $0.05\sigma_x$, donde $\sigma_x = 2769.269$.

Cuadro 7: *Importancia de la variable original y su copia.*

Configuración	Original	Copia	$\lvert\phi_{orig} + \phi_{copia}\rvert$
interventional	0.508211	0.183287	0.517805
tree_path_dependent	0.426735	0.202834	0.494598

Con SHAP intervencional, la original conserva más crédito que la copia y su contribución conjunta queda cerca de la importancia original sin copia. La configuración dependiente de trayectorias reduce la original y eleva ligeramente la copia.

El axioma de simetría repartiría el crédito por igual solo si ambas variables fueran jugadores intercambiables para la función de valor. El ruido y las decisiones de partición del entrenamiento rompen esa equivalencia. Además, `tree_path_dependent` pondera con los conteos de rutas del árbol y no integra la distribución condicional real; no debe interpretarse como importancia causal.

Task 2.4: KernelSHAP frente a TreeSHAP

Cuadro 8: *Error y tiempo de KernelSHAP para 10 instancias y 2,000 muestras por instancia.*

Fondo	MAE vs TreeSHAP	Tiempo total, s	s/instancia
10	0.045059	1.217	0.1217
50	0.030571	4.234	0.4234
100	0.032234	7.677	0.7677

El tiempo crece de 1.217 s a 7.677 s cuando el fondo aumenta de 10 a 100, comportamiento compatible con un costo proporcional al número de muestras por el tamaño del fondo. El MAE baja de 0.045059 a 0.030571 con 50 filas, pero sube ligeramente a 0.032234 con 100. Aumentar el fondo no garantiza una disminución monótona porque cambian la referencia y la aproximación por muestreo.

Task 2.5: Fórmula exacta de Shapley

Se entrenó un modelo con `duration`, `credit_amount`, `installment_commitment`, `residence_since`, `age` y `existing_credits`. Para cada una de cinco instancias se enumeraron las 64 coaliciones. Cada $v(S)$ promedió el log-odds sobre 50 filas del fondo, fijando en el cliente las variables presentes en S. La implementación propia aplicó el peso

$$\frac{|S|!\,(M - |S| - 1)!}{M!}.$$

Cuadro 9: *Error de eficiencia de la implementación propia.*

Instancia	Error absoluto
0	8.327×10^{-17}
1	2.220×10^{-16}
2	5.551×10^{-16}
3	0
4	1.388×10^{-16}

Cuadro 10: *Comparación contra TreeSHAP.*

Verificación	Error máximo
Implementación propia vs TreeSHAP	2.431×10^{-8}
Eficiencia de los ϕ propios	5.551×10^{-16}

El máximo frente a TreeSHAP es 2.43×10^{-8} y la eficiencia propia llega a 5.55×10^{-16}, prácticamente precisión doble. La diferencia contra TreeSHAP es consistente con la precisión numérica usada internamente por los árboles.

Task 2.6: Análisis de confiabilidad

(a) Escala. Para el cliente rechazado, $P(x) = 0.051742$ y la probabilidad base es 0.807017. La suma de efectos individuales transformados a probabilidad es -0.945725, mientras el cambio real es -0.755275. Los valores SHAP suman exactamente en log-odds, pero la sigmoide es no lineal; por ello, transformar cada ϕ_j por separado rompe la aditividad.

(b) Rankings. La mayor diferencia de posición corresponde a `age`, con brecha 14. Sus correlaciones de Spearman de mayor magnitud son `housing` (-0.312), `employment` ($+0.306$), `personal_status` ($+0.273$), `residence_since` ($+0.245$) y `credit_history` (-0.200). La redundancia moderada apoya la hipótesis de que, al permutar `age`, otras variables conservan parte de la información aunque SHAP todavía le atribuya contribuciones locales grandes.

(c) Crédito duplicado. La importancia conjunta de la original y su copia se mantiene cercana a la original del modelo base, pero el reparto no es igual. El crédito depende de la representación, la dependencia entre variables, el fondo y la estructura aprendida; no identifica por sí solo una causa real.

(d) Costo computacional.

Cuadro 11: *Mediciones y estimaciones de costo.*

Cantidad	Resultado
Predicción de 100 instancias	0.001880 s
Estimación exacta, 20 variables	1,971.2 s, 0.548 h
KernelSHAP, fondo 100	0.7677 s/instancia
Razón exacto / KernelSHAP	2,568 veces
Exacto, 60 variables a 1 microsegundo/evaluación	36,533.9 años

Una evaluación de $v(S)$ requiere procesar las 100 filas del fondo. Con el tiempo medido para ese lote, enumerar 2^{20} coaliciones se estima en 1,971.2 s, frente a 0.7677 s por instancia para KernelSHAP con fondo 100. Con 60 variables, incluso una evaluación idealizada de un microsegundo llevaría alrededor de 36,534 años. La aproximación es necesaria para dimensionalidades reales.

Task 3: LIME y contrafactuales

Task 3.1: LIME tabular desde cero

Se implementó LIME sin la librería homónima. Cada perturbación usa una representación binaria de las 20 variables; una variable ausente se sustituye por un valor muestreado de su columna de entrenamiento. Con $N = 5{,}000$, $K = 5$, $\lambda = 1$ y $\sigma = 0.75\sqrt{20}$, los pesos son $\pi_x(z) = \exp(-D^2/\sigma^2)$. La solución ridge ponderada se calculó en forma cerrada y el intercepto no se penalizó.

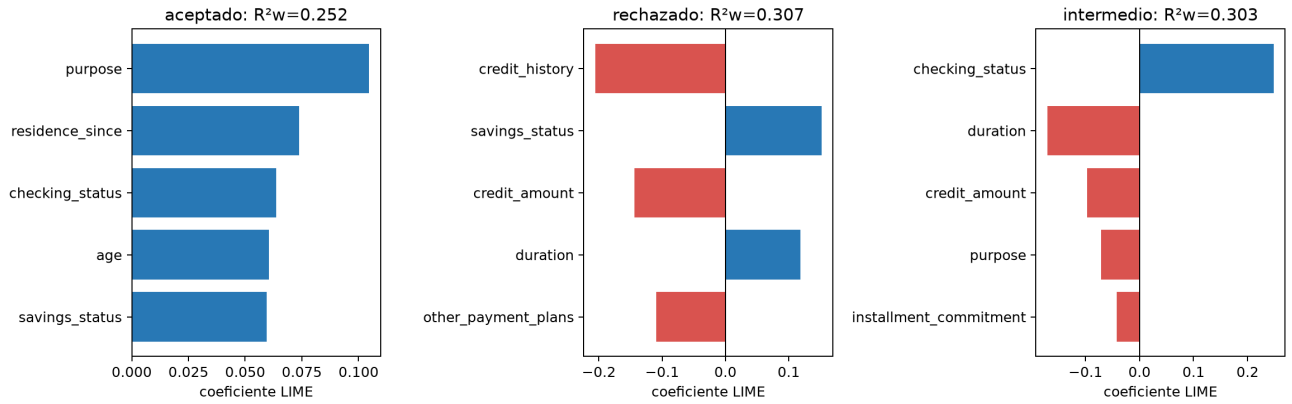


Figura 7: *Coeficientes de las cinco variables seleccionadas por LIME para los tres clientes.*

Cuadro 12: *Resultados locales de LIME.*

Cliente	Variable	Coeficiente	R_w^2
Aceptado	purpose	0.1046	0.2523
Aceptado	residence_since	0.0739	
Aceptado	checking_status	0.0638	
Aceptado	savings_status	0.0594	
Aceptado	age	0.0604	
Rechazado	credit_history	-0.2058	0.3070
Rechazado	savings_status	0.1521	
Rechazado	credit_amount	-0.1436	
Rechazado	duration	0.1185	
Rechazado	other_payment_plans	-0.1096	
Intermedio	checking_status	0.2486	0.3027
Intermedio	duration	-0.1707	
Intermedio	credit_amount	-0.0965	
Intermedio	purpose	-0.0708	
Intermedio	installment_commitment	-0.0423	

Las probabilidades de los clientes aceptado, rechazado e intermedio fueron 0.999447, 0.051742 y 0.503997. Las fidelidades entre 0.252 y 0.307 son bajas: los coeficientes permiten describir la aproximación local, pero no justifican usarla por sí sola en una decisión.

Task 3.2: Estabilidad de LIME

Se realizaron 20 corridas por cada combinación de N y σ_{rel}. El Jaccard se promedió sobre los 190 pares de corridas, y $N_{ef} = (\sum_n \pi_n)^2 / \sum_n \pi_n^2$.

Cuadro 13: *Jaccard medio de las cinco variables seleccionadas.*

N	$\sigma_{rel} = 0.5$	$\sigma_{rel} = 0.75$	$\sigma_{rel} = 1.5$
500	0.734	0.763	0.751
2,000	0.967	0.967	0.967
5,000	1.000	1.000	1.000

Cuadro 14: *Tamaño efectivo medio.*

N	$\sigma_{rel} = 0.5$	$\sigma_{rel} = 0.75$	$\sigma_{rel} = 1.5$
500	407.9	480.7	498.8
2,000	1,640.6	1,924.0	1,995.1
5,000	4,097.3	4,806.8	4,987.7

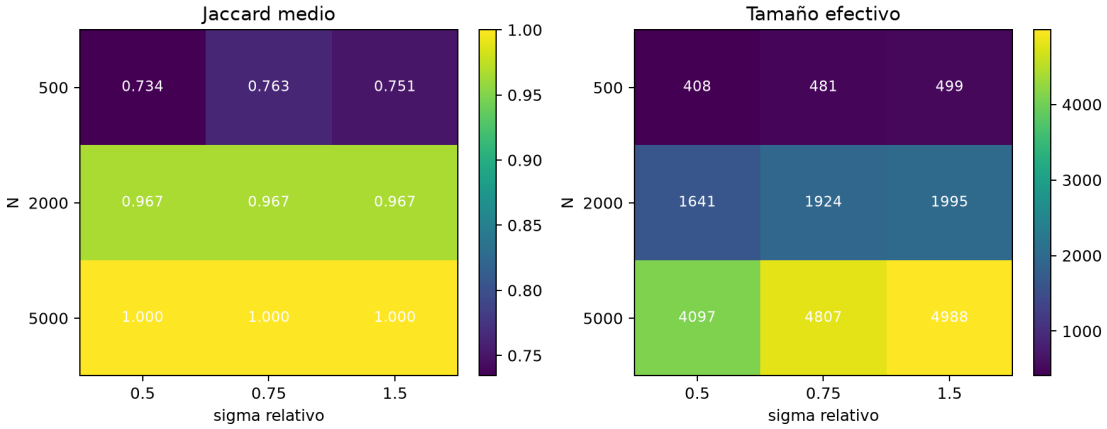


Figura 8: *Estabilidad y tamaño efectivo de LIME para las nueve configuraciones.*

Al crecer N_{ef}, el Jaccard pasa de valores cercanos a 0.75 con 500 muestras a estabilidad perfecta con 5,000. El ancho modifica mucho más N_{ef} cuando $\sigma_{rel} = 0.5$, porque el kernel concentra el peso en menos perturbaciones.

Task 3.3: Comparación entre LIME y SHAP

Cuadro 15: *Acuerdo entre los rankings locales de LIME y SHAP.*

Cliente	**Spearman**	**Top 3 comunes**	**Variables comunes**
Aceptado	0.817	2	checking_status, purpose
Rechazado	0.926	3	credit_amount, credit_history, savings_status
Intermedio	0.917	3	checking_status, credit_amount, duration

Cuadro 16: *Fidelidad de LIME para el cliente rechazado.*

K	R^2_w
3	0.2164
5	0.3063
10	0.3644
20	0.3719

El acuerdo de ranking es alto, especialmente para el rechazado y el intermedio, pero la fidelidad absoluta de LIME sigue siendo limitada. Aumentar de 10 a 20 variables solo mejora R^2_w de 0.3644 a 0.3719, señal de que el problema no se resuelve sacrificando toda la comprensibilidad.

Task 3.4: Explicaciones contrafactuales

Se muestrearon 20,000 candidatos con un máximo de tres cambios entre `duration`, `credit_amount`, `installment_commitment`, `checking_status` y `savings_status`. Las variables `age`, `personal_status` y `foreign_worker` se mantuvieron inmutables. No fue necesario aumentar el máximo de cambios.

Cuadro 17: *Tres contrafactuales válidos con conjuntos de cambios distintos.*

CF	Cambios: original → nuevo	Distancia	$P(good)$
1	credit_amount: 433 → 454; checking_status: $0 \leq X < 200$ → no checking	1.020	0.596
2	duration: 6 → 7; credit_amount: 433 → 458; checking_status: $0 \leq X < 200$ → no checking	1.190	0.596
3	credit_amount: 433 → 426; installment_commitment: 4 → 2	2.007	0.585

La validez fue 0.00615: 123 de 20,000 candidatos superaron el umbral de 0.5. Entre los candidatos válidos, la distancia promedio fue 4.047 y se modificaron 2.789 variables en promedio. Los tres seleccionados son más próximos que ese promedio y mantienen conjuntos de variables distintos.

Task 3.5: Análisis de confiabilidad

(a) Estabilidad. Se ajustó una relación lineal entre J y $1/\sqrt{N_{ef}}$ para $\sigma_{rel} = 0.75$. La extrapolación estimó $N = 1{,}500$ para $J = 0.9$. Veinte corridas adicionales, no usadas en el ajuste, produjeron $J = 0.907$ y $N_{ef} = 1{,}441.1$, por lo que la estimación quedó verificada.

(b) Discrepancia. La mayor brecha ocurrió para el cliente aceptado y `other_payment_plans`: puesto 20 en LIME frente a puesto 8 en SHAP, diferencia de 12. Al reducir σ_{rel} de 0.75 a 0.5, la variable subió al puesto 12 en LIME. La mejora apoya un efecto de localidad; la curva por niveles también muestra que el codificador ordinal y las divisiones del *gradient boosting* producen una respuesta no lineal.

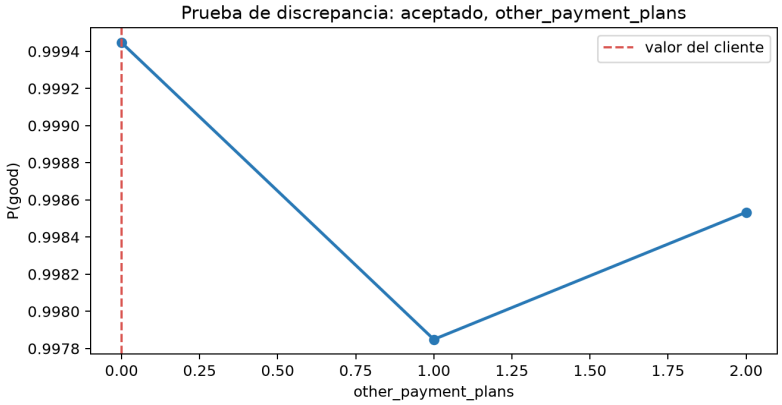


Figura 9: *Probabilidad al variar solo la variable con mayor discrepancia LIME-SHAP.*

(c) Elección de K. Se propuso $R^2_w \geq 0.80$ como mínimo para presentar LIME en una decisión de crédito. Ningún K lo alcanzó; aun con $K = 20$, $R^2_w = 0.372$. Por ello no se aceptaría esta explicación como suficiente. Se revisaría el vecindario, la representación o una técnica alternativa validada antes de comunicarla.

(d) SHAP frente a contrafactuales. Las tres mayores contribuciones absolutas del rechazado fueron `credit_history`, `savings_status` y `credit_amount`. Los contrafactuales usaron `checking_status`, `credit_amount`, `duration` y `installment_commitment`. `credit_history`, con $\phi = -1.3162$, no aparece porque no es accionable en la búsqueda. SHAP atribuye la predicción observada respecto de un fondo; el contrafactual busca cambios permitidos de baja distancia que crucen un umbral.

Task 4: Validación de explicaciones

Task 4.1: Deletion e insertion

Cada métrica usa 20 pasos y diez órdenes aleatorios. En *deletion*, una mejora positiva significa que el AUC del mapa es menor que el del azar; en *insertion*, significa que es mayor. Los puntajes z expresan la diferencia en desviaciones estándar de la referencia aleatoria.

Cuadro 18: *Validación cuantitativa de Grad-CAM.*

Imagen	Del. mapa	Del. azar	z_{del}	Ins. mapa	Ins. azar	z_{ins}
(a)	0.0471	0.1719 ± 0.0261	4.77	0.5924	0.1989 ± 0.0165	23.78
(b)	0.0463	0.0059 ± 0.0022	-18.41	0.6198	0.0896 ± 0.0136	39.03
(c)	0.00001	0.0100 ± 0.0080	1.25	0.8594	0.0944 ± 0.0075	102.26

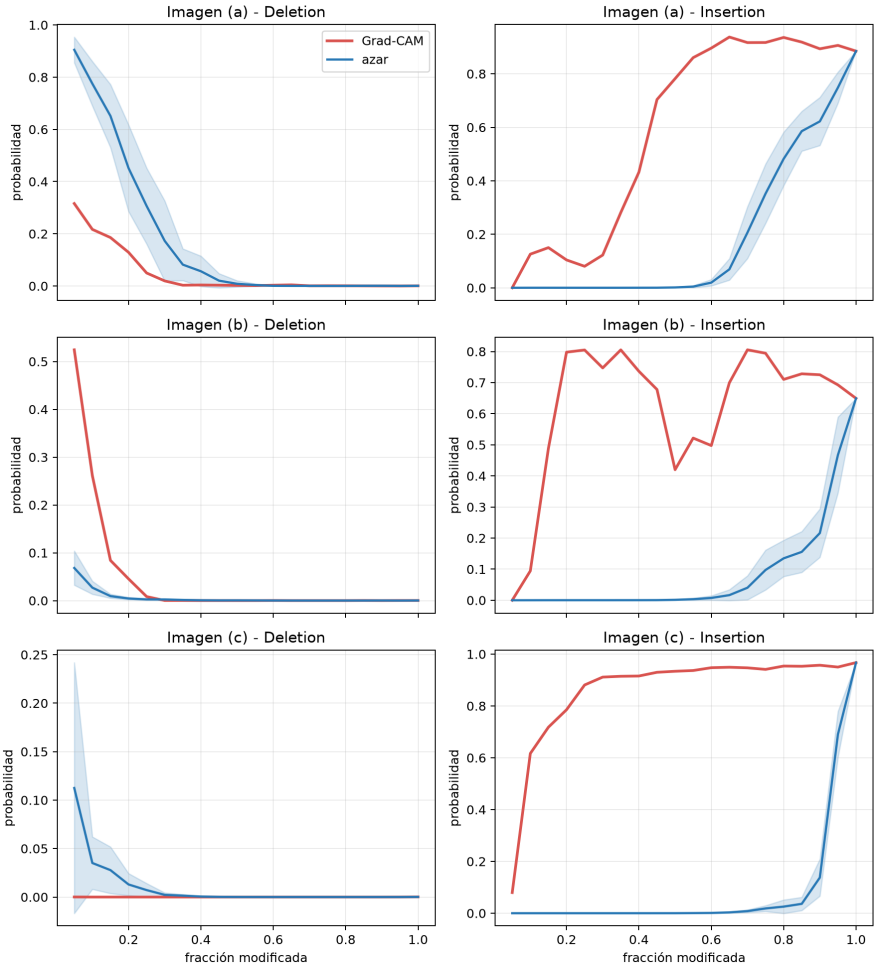


Figura 10: *Curvas del mapa Grad-CAM y media del azar; la banda representa una desviación estándar.*

Grad-CAM supera claramente al azar en *insertion* para las tres imágenes. En *deletion*, (a) supera al azar por 4.77 desviaciones y (c) solo por 1.25, mientras (b) es peor por 18.41. Esto impide declarar validez uniforme: el mapa de (b) inserta evidencia útil temprano, pero los parches grises de su región principal no destruyen la clase tan rápido como un orden aleatorio.

Task 4.2: Aleatorización en cascada

Cuadro 19: *Spearman entre el mapa original y el mapa tras reinicialización acumulativa.*

Etapa	Imagen (a)	Imagen (b)	Imagen (c)
fc	0.607	0.246	-0.047
layer4	0.201	0.281	0.294
layer3	-0.065	0.282	0.311
layer2	-0.015	-0.093	-0.210
layer1	-0.306	-0.311	-0.242
conv1	0.403	-0.348	-0.380

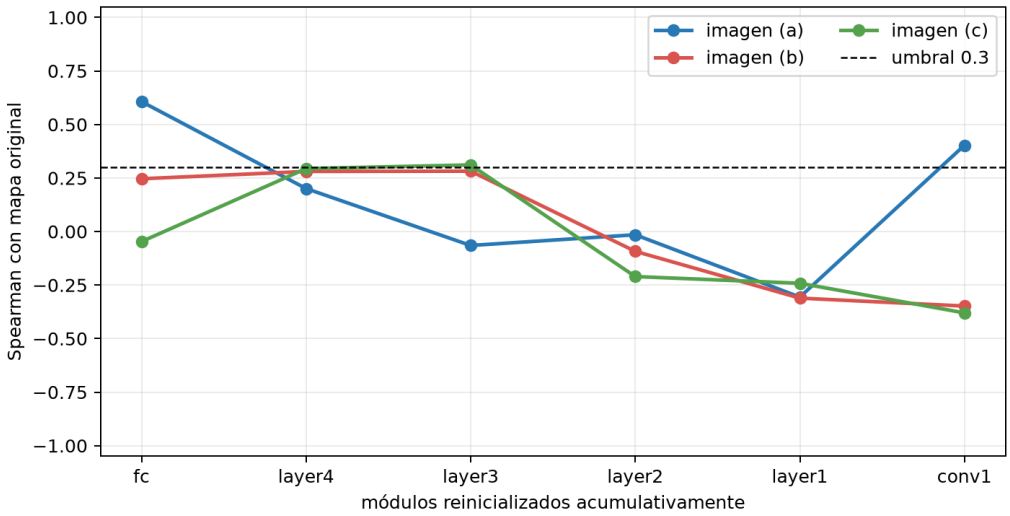


Figura 11: *Sensibilidad del mapa a la aleatorización progresiva de parámetros.*

La correlación cae por debajo de 0.3 en `layer4` para (a), y desde `fc` para (b) y (c). Al aleatorizar solo `fc`, las activaciones no cambian, pero sí los pesos de clase y, por $\alpha_k^c = w_k^c/Z$, debe cambiar la combinación de canales. Esto ocurre de inmediato en (b) y (c). En (a) queda una correlación residual de 0.607, pero desaparece al reinicializar `layer4`; una coincidencia visual aislada no prueba dependencia correcta del modelo.

Task 4.3: Interpretación, audiencias y riesgo

(a) Referencia de perturbación. Para la imagen (a), el AUC de *deletion* pasa de 0.0471 con gris medio a 0.0917 con desenfoque. El orden de importancia es el mismo, así que la diferencia cuantifica el efecto del parche de referencia. Las curvas escalonadas son coherentes con un mapa original de solo 7×7 posiciones interpolado a 224 por 224.

(b) Dependencia de parámetros. La cascada confirma que los mapas no permanecen invariantes a la red, pero la respuesta no es monótona porque cada reinicialización altera simultáneamente activaciones, gradientes y empates de rango. El resultado de (a) exige mirar la cascada completa, no solo la primera etapa.

(c) Audiencias. A la persona solicitante se entregarían razones locales en lenguaje claro y, solo para crédito, cambios accionables factibles; no se expondrían log-odds ni una lista técnica sin contexto. Al oficial de cumplimiento se entregarían SHAP local y global, el error de eficiencia 9.72×10^{-8}, la estabilidad de LIME y sus bajos R_w^2, además de las restricciones contrafactuales. Al regulador se agregarían procedencia, codificación, semillas, supuestos, pruebas de robustez y trazabilidad reproducible. Ninguna explicación se presentaría como causal.

En detección de lavado, revelar un contrafactual exacto permitiría adaptar transacciones para evadir el umbral. Se entregarían categorías generales de señales, evidencia agregada, justificación para revisión humana, controles de auditoría y un canal de apelación, sin publicar umbrales ni combinaciones accionables.

Conclusiones

Las identidades de CAM y Grad-CAM se verificaron hasta errores de `float32`, pero las pruebas de perturbación y aleatorización mostraron que un mapa visual no sustituye una validación: *insertion* fue fuerte en las tres imágenes, mientras *deletion* falló frente al azar en (b). En crédito, TreeSHAP cumplió eficiencia y la implementación exacta reprodujo sus valores con errores menores que 2.5×10^{-8}.

LIME fue estable desde aproximadamente 2,000 muestras, pero su fidelidad para el cliente rechazado no superó 0.372 ni usando las 20 variables. Los contrafactuales sí hallaron cambios válidos y próximos, aunque solo 0.615 % de los candidatos cruzó el umbral. En conjunto, una explicación solo es defendible cuando se especifican su escala, referencia, restricciones, audiencia y evidencia de fidelidad, estabilidad y sensibilidad.

El notebook adjunto conserva el código, las salidas y todas las figuras utilizadas en este documento.