CC3045: Deep Learning

Laboratorio 10

Entrega parcial: Tasks 1 y 2

Milton Polanco - 23471 | Olivier Viau

Configuración	Valor
Semilla aleatoria	42
Modelo de visión	ResNet-18 preentrenado en ImageNet
Modelo tabular	Gradient Boosting, 200 árboles, profundidad 3
Partición	80 % entrenamiento, 20 % prueba, estratificada
Fondo principal SHAP	100 instancias de entrenamiento

El análisis se apoya en las cifras y figuras producidas por la ejecución incluida en el notebook. Las probabilidades se reportan para la clase indicada; en crédito, *good* se codifica como 1 y *bad* como 0.

Declaración de herramientas de apoyo. Se utilizó asistencia de IA para apoyar la escritura de fórmulas, depurar errores de ejecución y comprobar que no faltaran puntos de los Tasks 1 y 2. Prompt de apoyo: “Revisa las fórmulas, señala errores de ejecución y comprueba si falta algún punto de los Tasks 1 y 2”. Fue útil porque permitió contrastar las fórmulas y conclusiones con las salidas ejecutadas y con la guía.

Task 1: Grad-CAM y CAM

Task 1.1: Modelo, preprocesamiento e imágenes

Se cargó ResNet-18 con pesos de ImageNet y se fijó en modo de evaluación. Cada imagen se redimensionó a 256 píxeles en el lado corto, se recortó al centro a 224×224 y se normalizó por canal con media $(0.485, 0.456, 0.406)$ y desviación estándar $(0.229, 0.224, 0.225)$.



Figura 1: *Imágenes después del preprocesamiento geométrico. En (c), el recuadro del perro es* $(58, 20, 174, 214)$ *en coordenadas* $(x_{\text{mín}}, y_{\text{mín}}, x_{\text{máx}}, y_{\text{máx}})$.

Cuadro 1: *Cinco clases de mayor probabilidad para cada imagen.*

Imagen	Rango	Clase	Probabilidad
(a)	1	Samoyed	0.884793
(a)	2	Arctic fox	0.045711
(a)	3	white wolf	0.044211
(a)	4	Pomeranian	0.005623
(a)	5	Great Pyrenees	0.004655
(b)	1	Rhodesian ridgeback	0.649178
(b)	2	American Staffordshire terrier	0.106260
(b)	3	bull mastiff	0.053913
(b)	4	Great Dane	0.051081
(b)	5	boxer	0.050373
(c)	1	Shetland sheepdog	0.967136
(c)	2	collie	0.027508
(c)	3	Pomeranian	0.003798
(c)	4	shopping basket	0.000333
(c)	5	Pembroke	0.000296

La imagen (a) se reconoce como *Samoyed* con probabilidad 0.884793. En (b), las cinco primeras clases son razas de perro y el gato no aparece entre ellas; la evidencia del perro domina la predicción global. En (c), el perro se reconoce como *Shetland sheepdog* con 0.967136. *Shopping basket* aparece en cuarto lugar, con 0.000333.

Fuentes de las imágenes. (a) PyTorch Hub: *dog.jpg*. (b) Peretz Partensky, Wikimedia Commons: *Cat and dog standoff*, CC BY-SA 2.0. (c) Kokostephi, Wikimedia Commons: *Shetland Sheepdog in Shopping Cart at Petco*, CC0.

Task 1.2: Grad-CAM desde cero

Se registró un hook de avance sobre `layer4` para guardar las activaciones A de 512 canales y tamaño 7×7, y un hook de retroceso para guardar el gradiente del logit de la clase antes del softmax. Para cada canal se calculó

$$\alpha_k^c = \frac{1}{49} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k}, \qquad L^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k \right).$$

El mapa se amplió a 224×224 con interpolación bilineal y se normalizó con su mínimo y máximo.

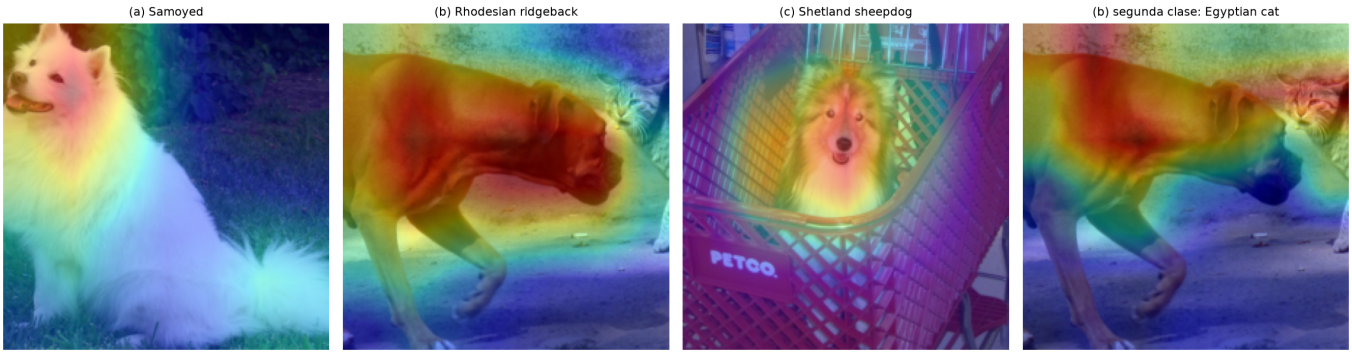


Figura 2: *Grad-CAM para la clase principal de cada imagen y, en (b), para la mejor clase felina: Egyptian cat.*

En (a) el mapa cubre el cuerpo y la cabeza del perro. En (b), los mapas de *Rhodesian ridgeback* y *Egyptian cat* cambian su énfasis espacial, aunque conservan una región compartida cerca del contacto entre los animales. En (c), la activación principal cae sobre el perro y parte del carrito inmediato.

Task 1.3: Verificación de CAM y su relación con Grad-CAM

Como ResNet-18 aplica promedio global antes de la capa lineal, CAM se obtiene sin gradientes mediante

$$M_{ij}^c = \sum_k w_k^c A_{ij}^k.$$

La descomposición esperada es $\frac{1}{49} \sum_{i,j} M_{ij}^c + b^c = y^c$. Además, antes de ReLU y normalización debe cumplirse $49 L^c = M^c$.

Cuadro 2: *Comprobaciones numéricas entre CAM y Grad-CAM.*

Imagen	Clase	Logit	CAM+b	Error logit	Error $49L$	Error norm.
(a)	Samoyed	16.273741	16.273743	1.907×10^{-6}	7.629×10^{-6}	1.788×10^{-7}
(b)	Rhodesian ridgeback	14.713373	14.713374	9.537×10^{-7}	3.815×10^{-6}	1.788×10^{-7}
(c)	Shetland sheepdog	17.980591	17.980591	0	7.629×10^{-6}	1.192×10^{-7}

La descomposición del logit coincide hasta un máximo de 1.91×10^{-6}. El error máximo entre 49 veces Grad-CAM sin ReLU y CAM es 7.63×10^{-6}; después de ReLU y normalización, el máximo es 1.79×10^{-7}. Las diferencias corresponden al redondeo de precisión simple.

Task 1.4: Análisis cuantitativo

(a) Gradientes y pesos. La derivada es constante en las 49 posiciones porque el pooling global promedia cada canal antes de la capa lineal:

$$\frac{\partial y^c}{\partial A_{ij}^k} = \frac{w_k^c}{49}.$$

Cuadro 3: *Comparación de α_k^c contra $w_k^c/49$ en los cinco canales de mayor $|w|$.*

Canal	α observado	$w/49$	Error relativo
31	0.0070189578	0.0070189578	0
83	0.0052330079	0.0052330079	0
314	0.0051479875	0.0051479880	9.046×10^{-8}
454	0.0045764870	0.0045764870	0
378	0.0044133649	0.0044133654	1.055×10^{-7}

Tres canales coinciden exactamente en la representación utilizada. Los otros dos tienen errores relativos cercanos a 10^{-7}. El orden de las sumas, los promedios y la retropropagación en `float32` explica que el resultado no sea cero exacto.



Figura 3: *Comparación espacial de las dos clases de (b) y mapa de (c) con el recuadro del objeto.*

(b) Separación de clases. La IoU entre los píxeles del 20 % superior es 0.224668. Este valor indica que el mapa discrimina buena parte de la evidencia del perro y del gato, aunque existe solapamiento. La resolución original de 7×7 impone un paso efectivo de 32 píxeles: dos objetos pequeños o cercanos pueden compartir una celda y no admiten una frontera precisa.

(c) Fondo y prueba causal. El 69.55 % de la masa normalizada cae dentro del recuadro. Al neutralizar el exterior, P(Shetland sheepdog) baja de 0.967136 a 0.819089, un cambio de -0.148047. El objeto concentra la mayoría de la evidencia, pero el exterior aporta soporte medible. Hay dependencia contextual, aunque no un atajo dominante, porque la clase conserva probabilidad 0.819089 sin el fondo original.

Task 2: Explicaciones de riesgo de crédito

Task 2.1: Datos y modelo base

German Credit contiene 1,000 solicitudes, 7 variables numéricas y 13 categóricas. Se codificó *good* como 1 y *bad* como 0. El codificador ordinal se ajustó solo con entrenamiento. Los códigos son arbitrarios y el árbol puede tratarlos como si existiera un orden y una distancia; esta es una limitación para interpretar divisiones y atribuciones.

Cuadro 4: *Desempeño sobre el conjunto de prueba.*

Métrica	Resultado
Exactitud	0.775
AUC	0.765

El AUC de 0.765 indica una separación útil pero imperfecta. Las explicaciones deben acompañarse de métricas de fidelidad y no presentarse como justificaciones causales.

Task 2.2: TreeSHAP intervencional

La salida explicada es el log-odds de `decision_function`. El fondo contiene 100 instancias de entrenamiento seleccionadas sin reemplazo con semilla 42.

Cuadro 5: *Comprobaciones principales de TreeSHAP.*

Comprobación	Resultado
Error absoluto máximo de eficiencia	9.722×10^{-8}
Valor base SHAP, log-odds	1.430742147
Media del log-odds sobre el fondo	1.430742147
Spearman entre rankings completos	0.649624

La eficiencia se cumple hasta 9.72×10^{-8} y el valor base coincide con la media del fondo en todos los dígitos mostrados. Esto valida la escala y la referencia utilizadas.

Cuadro 6: *Cinco variables principales según SHAP y permutación.*

Rango	SHAP	mean $\lvert\phi\rvert$	Permutación	Caída AUC
1	checking_status	0.760287	checking_status	0.119000
2	purpose	0.511731	credit_amount	0.076250
3	credit_amount	0.490213	duration	0.057905
4	duration	0.391748	credit_history	0.039643
5	savings_status	0.296328	savings_status	0.026155

Ambos métodos colocan `checking_status` primero. SHAP eleva `purpose` al segundo lugar, mientras permutación prioriza `credit_amount` y `duration`. La correlación de 0.649624 muestra acuerdo moderado: ambos métodos responden preguntas diferentes.

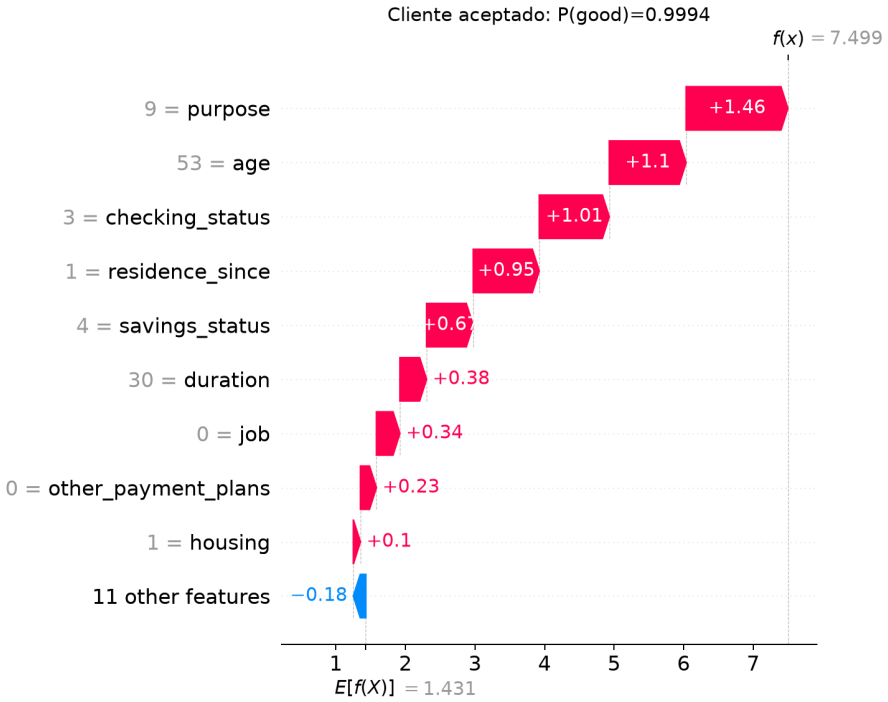


Figura 4: *Cliente aceptado, posición 50 del conjunto de prueba,* $P(good) = 0.999447$.

Las contribuciones de mayor magnitud son positivas: *purpose* (+1.463294), *age* (+1.104481) y *checking status* (+1.006869). Las tres desplazan el log-odds hacia *good*.

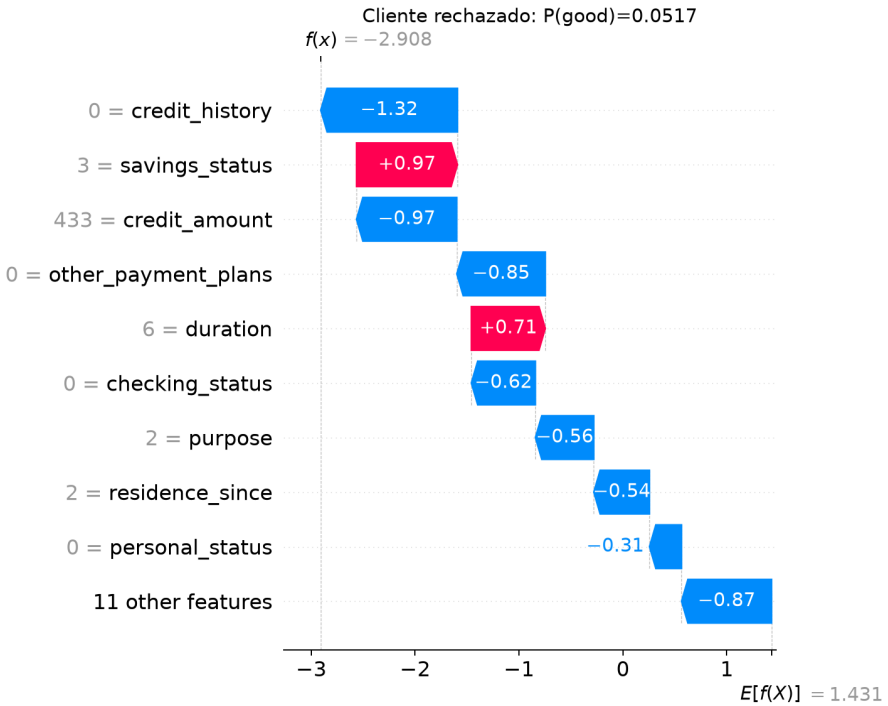


Figura 5: *Cliente rechazado, posición 76 del conjunto de prueba,* $P(good) = 0.051742$.

En el cliente rechazado, `credit_history` (−1.316188) y `credit_amount` (−0.965395) empujan hacia *bad*; `savings_status` (+0.972107) compensa parte del efecto. El signo describe el cambio en log-odds respecto al fondo, no una relación causal.

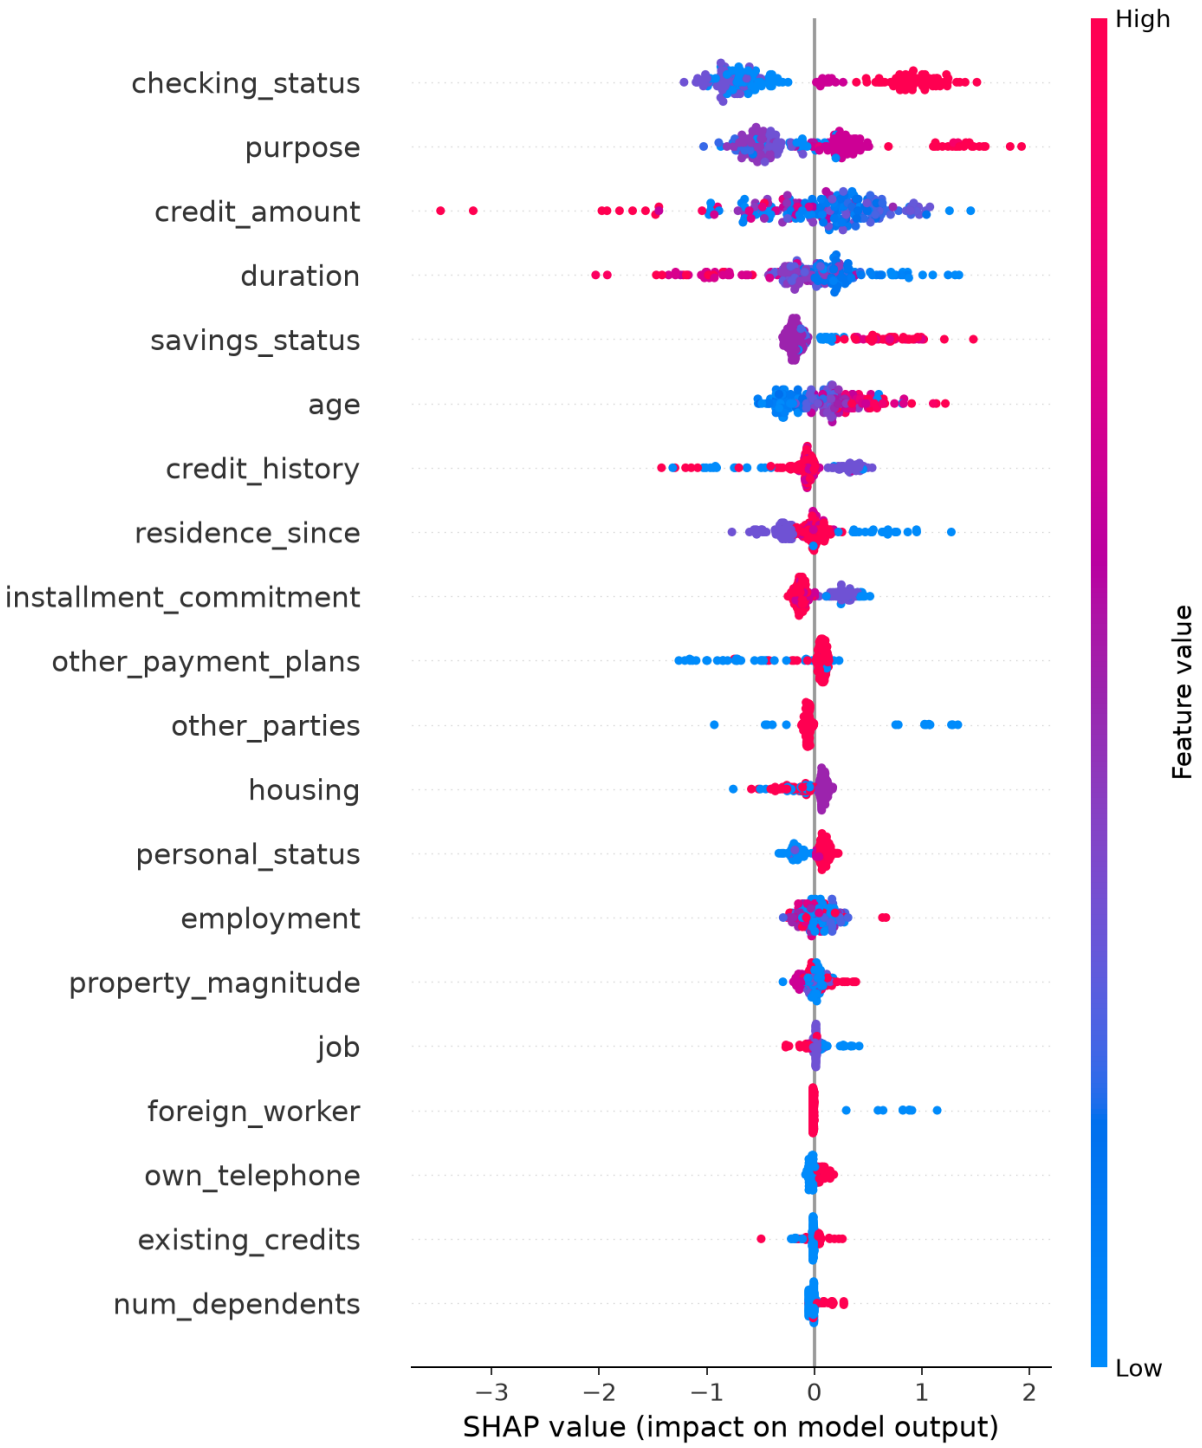


Figura 6: *Beeswarm global del conjunto de prueba. La posición horizontal es la contribución al log-odds y el color representa el valor codificado.*

Task 2.3: Variable redundante

La variable numérica de mayor importancia fue `credit_amount`, con mean $|\phi| = 0.490213$. Se creó una copia con ruido gaussiano de escala $0.05\sigma_x$, donde $\sigma_x = 2769.269$.

Cuadro 7: *Importancia de la variable original y su copia.*

Configuración	Original	Copia	$\lvert\phi_{orig} + \phi_{copia}\rvert$
interventional	0.508211	0.183287	0.517805
tree_path_dependent	0.426735	0.202834	0.494598

Con SHAP intervencional, la original conserva más crédito que la copia y su contribución conjunta queda cerca de la importancia original sin copia. La configuración dependiente de trayectorias reduce la original y eleva ligeramente la copia.

El axioma de simetría repartiría el crédito por igual solo si ambas variables fueran jugadores intercambiables para la función de valor. El ruido y las decisiones de partición del entrenamiento rompen esa equivalencia. Además, `tree_path_dependent` pondera con los conteos de rutas del árbol y no integra la distribución condicional real; no debe interpretarse como importancia causal.

Task 2.4: KernelSHAP frente a TreeSHAP

Cuadro 8: *Error y tiempo de KernelSHAP para 10 instancias y 2,000 muestras por instancia.*

Fondo	MAE vs TreeSHAP	Tiempo total, s	s/instancia
10	0.045059	0.340	0.0340
50	0.030571	1.106	0.1106
100	0.032234	2.159	0.2159

El tiempo crece de 0.340 s a 2.159 s cuando el fondo aumenta de 10 a 100, comportamiento compatible con un costo proporcional al número de muestras por el tamaño del fondo. El MAE baja de 0.045059 a 0.030571 con 50 filas, pero sube ligeramente a 0.032234 con 100. Aumentar el fondo no garantiza una disminución monótona porque cambian la referencia y la aproximación por muestreo.

Task 2.5: Fórmula exacta de Shapley

Se entrenó un modelo con `duration`, `credit_amount`, `installment_commitment`, `residence_since`, `age` y `existing_credits`. Para cada una de cinco instancias se enumeraron las 64 coaliciones. Cada $v(S)$ promedió el log-odds sobre 50 filas del fondo, fijando en el cliente las variables presentes en S. La implementación propia aplicó el peso

$$\frac{|S|!\,(M - |S| - 1)!}{M!}.$$

Cuadro 9: *Error de eficiencia de la implementación propia.*

Instancia	Error absoluto
0	8.327×10^{-17}
1	2.220×10^{-16}
2	5.551×10^{-16}
3	0
4	1.388×10^{-16}

Cuadro 10: *Comparación contra TreeSHAP.*

Verificación	Error máximo
Implementación propia vs TreeSHAP	2.431×10^{-8}
Eficiencia de los ϕ propios	5.551×10^{-16}

El máximo frente a TreeSHAP es 2.43×10^{-8} y la eficiencia propia llega a 5.55×10^{-16}, prácticamente precisión doble. La diferencia contra TreeSHAP es consistente con la precisión numérica usada internamente por los árboles.

Task 2.6: Análisis de confiabilidad

(a) Escala. Para el cliente rechazado, $P(x) = 0.051742$ y la probabilidad base es 0.807017. La suma de efectos individuales transformados a probabilidad es -0.945725, mientras el cambio real es -0.755275. Los valores SHAP suman exactamente en log-odds, pero la sigmoide es no lineal; por ello, transformar cada ϕ_j por separado rompe la aditividad.

(b) Rankings. La mayor diferencia de posición corresponde a `age`, con brecha 14. Sus correlaciones de Spearman de mayor magnitud son `housing` (-0.312), `employment` ($+0.306$), `personal_status` ($+0.273$), `residence_since` ($+0.245$) y `credit_history` (-0.200). La redundancia moderada apoya la hipótesis de que, al permutar `age`, otras variables conservan parte de la información aunque SHAP todavía le atribuya contribuciones locales grandes.

(c) Crédito duplicado. La importancia conjunta de la original y su copia se mantiene cercana a la original del modelo base, pero el reparto no es igual. El crédito depende de la representación, la dependencia entre variables, el fondo y la estructura aprendida; no identifica por sí solo una causa real.

(d) Costo computacional.

Cuadro 11: *Mediciones y estimaciones de costo.*

Cantidad	Resultado
Predicción de 100 instancias	0.000532 s
Estimación exacta, 20 variables	558.0 s, 0.155 h
KernelSHAP, fondo 100	0.2159 s/instancia
Razón exacto / KernelSHAP	2,585 veces
Exacto, 60 variables a 1 microsegundo/evaluación	36,533.9 años

Una evaluación de $v(S)$ requiere procesar las 100 filas del fondo. Con el tiempo medido para ese lote, enumerar 2^{20} coaliciones se estima en 558.0 s, frente a 0.2159 s por instancia para KernelSHAP con fondo 100. Con 60 variables, incluso una evaluación idealizada de un microsegundo llevaría alrededor de 36,534 años. La aproximación es necesaria para dimensionalidades reales.

Conclusiones

Las identidades de CAM y Grad-CAM se verificaron hasta errores de `float32`, pero la prueba del fondo mostró que un mapa visual no sustituye una intervención. En crédito, TreeSHAP cumplió eficiencia y la implementación exacta reprodujo sus valores con errores menores que 2.5×10^{-8}. La discrepancia con permutación, el reparto inestable al duplicar una variable y la falta de aditividad en probabilidad muestran que una explicación solo es válida junto con su escala, referencia, supuestos de dependencia y pruebas numéricas.

El notebook adjunto conserva el código, las salidas y todas las figuras utilizadas en este documento.